Machine Learning – Ensembling

Concurso de la tele

En un concurso de la tele tenemos varios participantes. Se trata de acertar preguntas. Cuantas más aciertes, más dinero ganas. Veamos cómo lo hacen los participantes:

								VOTACIÓN
Pregunta 1	1	1	0	1	1	0	0	1
Pregunta 2	0	0	1	1	1	1	0	1
Pregunta 3	0	0	0	0	0	0	0	0
Pregunta 4	0	1	1	0	1	1	1	1
Pregunta 5	1	0	1	0	0	1	1	1
% ACIERTOS	**40%**	**40%**	**60%**	**40%**	**60%**	**60%**	**40%**	**80%**

¿Resultado? 7 concursantes trabajan mejor en equipo que de manera individual.
Este mismo comportamiento lo podemos extrapolar a los ensemblings

Definición

Los modelos ensamblados (ensemble models) combinan las decisiones de múltiples modelos para mejorar su precisión y estabilidad.

Se trata de modelos que se comportan muy bien y reducen bastante el variance. Este tipo de modelos son los que se suelen utilizar para ganar competiciones de Kaggle

Tipos de ensembles:

1. Bagging
    a. Random Forest
2. Boosting
    a. AdaBoost
    b. GradientBoost
    c. XGBoost

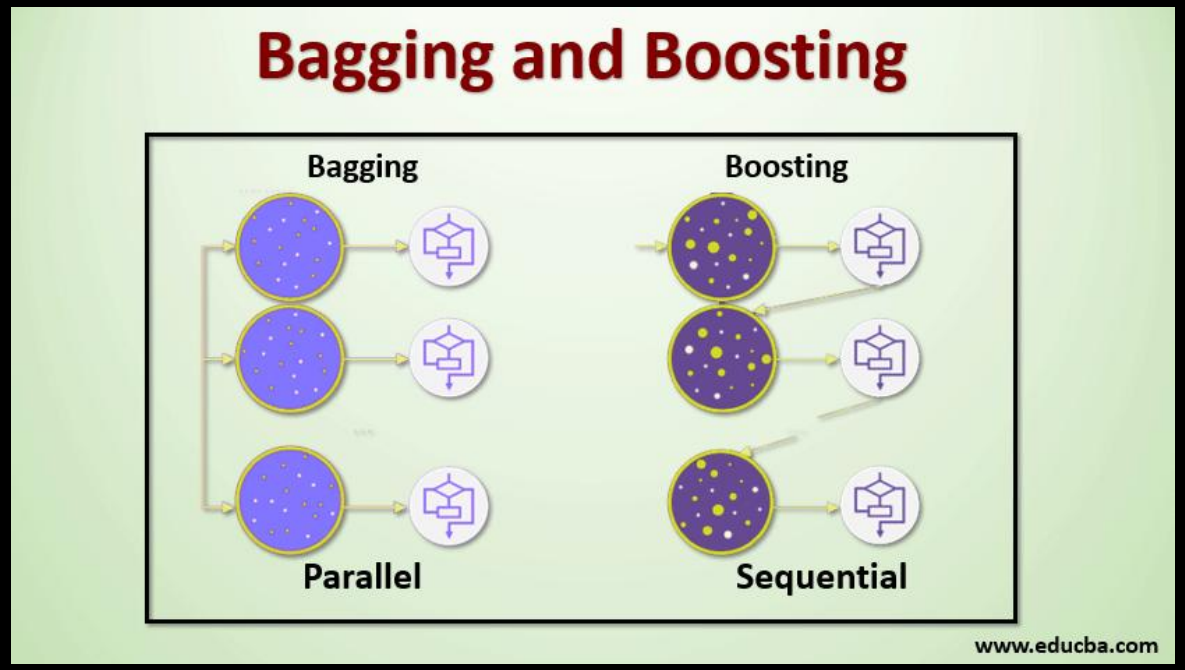

Tipos de Ensembles

Votación
Varios modelos trabajan en paralelo y se agregan sus outputs

Mismos modelos
Cada modelo del sistema de votación es del mismo tipo (DecissionTree, LogisticRegression…)

Distintos modelos (Voting)
Se combinan modelos de varios tipos para conformar el sistema de votaciones

Bagging
El muestreo para los modelos del ensemble se realiza mediante reemplazamiento (bootstrapping)

Pasting
El muestreo para los modelos del ensemble se realiza SIN mediante reemplazamiento

Secuenciales o Boosting
El output del primer modelo sirve de input para el siguiente, que corregirá los errores del anterior.

Para todos los modelos vistos en esta presentación tenemos las versiones de clasificación y regresión en sklearn

Votación

Algoritmos de votación

Votación
Varios modelos trabajan en paralelo y se agregan sus outputs

Mismos modelos
Cada modelo del sistema de votación es del mismo tipo (DecissionTree, LogisticRegression…)

Distintos modelos (Voting)
Se combinan modelos de varios tipos para conformar el sistema de votaciones

Bagging
El muestreo para los modelos del ensemble se realiza mediante reemplazamiento

Pasting
El muestreo para los modelos del ensemble se realiza SIN mediante reemplazamiento

Sklearn

Voting
VotingClassifier
VotingRegressor

Bagging
BaggingClassifier
BaggingRegressor

RandomForestClassifier
RandomForestRegressor

Pasting
BaggingClassifier
BaggingRegressor

¿Cómo se realizan las predicciones?

Clasificación – Hard voting
Se calcula la moda

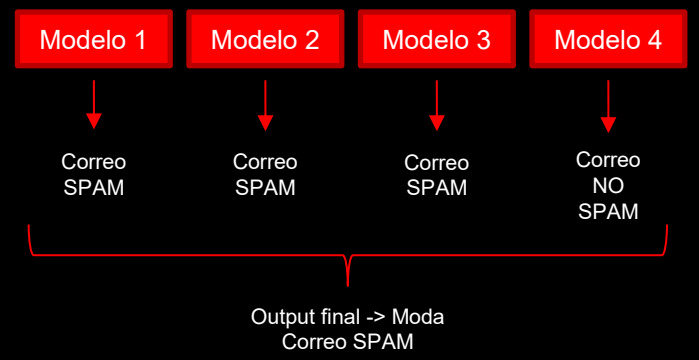

Clasificación – Soft Voting
La clase que tenga la probabilidad más alta dentro de los outputs de todos los modelos

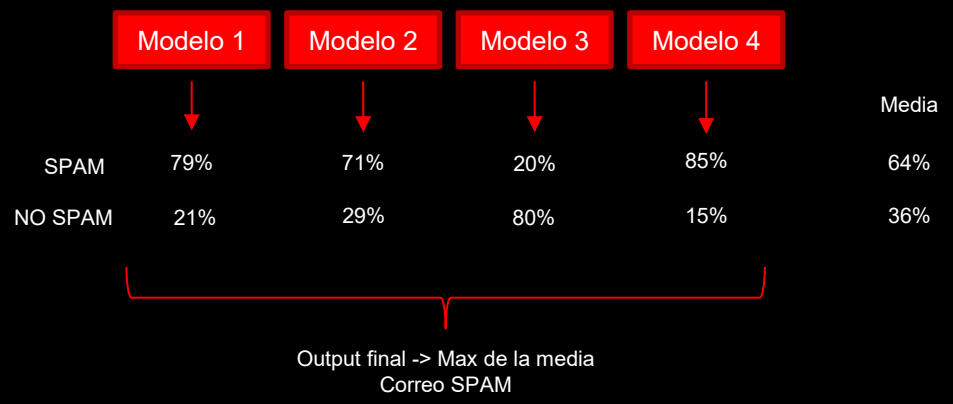

Regresión
Se calcula la media de todos los outputs

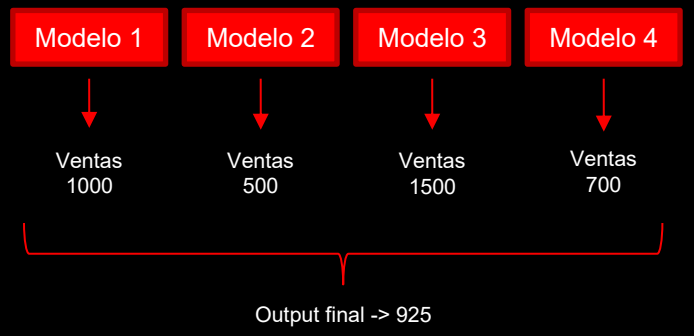

Voting

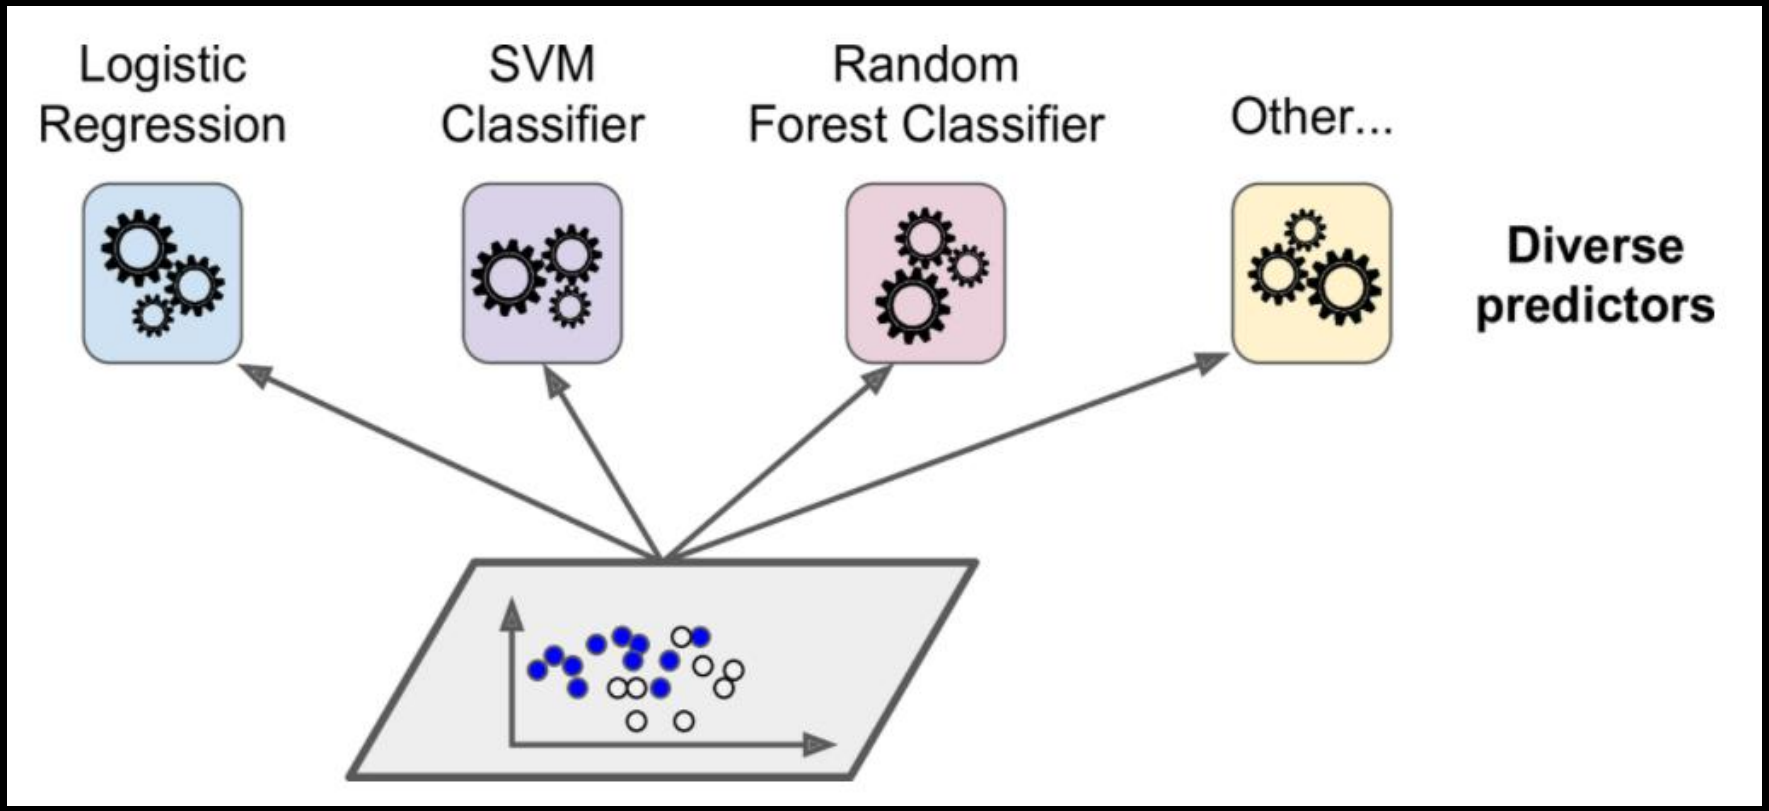
Logistic Regression
SVM Classifier
Random Forest Classifier
Other...
Diverse predictors

Bagging y Pasting

Bagging (Bootstrap Aggregating)

Con esta técnica se entrenan un conjunto de modelos, mediante muestras **con reemplazamiento**. Para cada predicción todos los modelos dan un output, y como si de un sistema de votación se tratase, se escoge como output final el más frecuente.

Esta técnica se usa tanto en **clasificación, como en regresión**. Si en clasificación utiliza la moda para elegir output, en regresión es la media de los outputs de todos los modelos.

Se trabaja con el mismo modelo

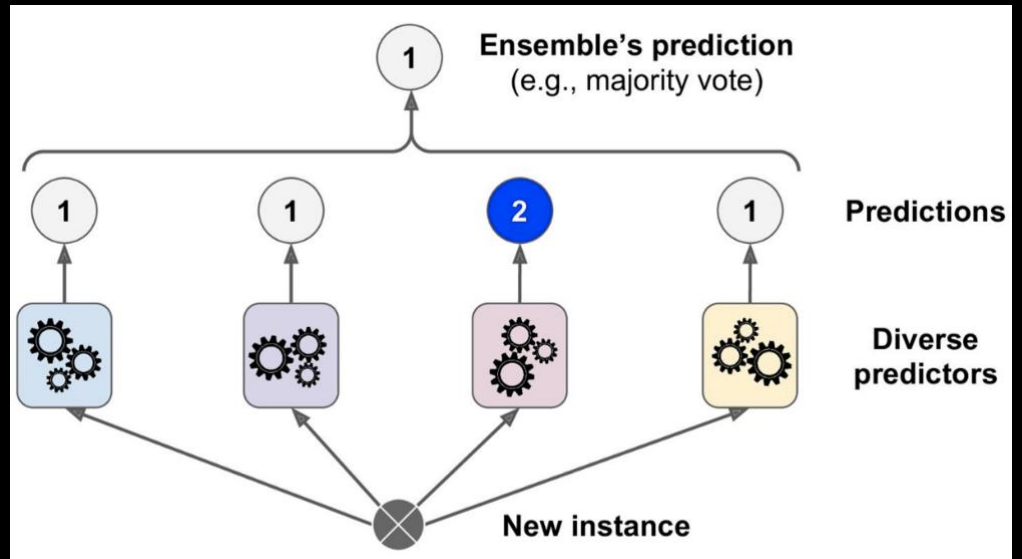

Figure 7-2. Hard voting classifier predictions

Pasting

Simplemente escogemos el argumento "bootstrap=False"
Suele funcionar mejor **<u>bagging</u>**

Random Forest Demo

https://waternova.github.io/random-forest-viz/

Random Forest

El algoritmo de bagging que más se utiliza es el random forest. Implementa el sistema de votación de bagging mediante árboles de decisión. **RandomForestClassifier y RandomForestRegressor.** Funciona de la siguiente manera:

1. Escogemos una cantidad de árboles que entrenaremos.
2. Cada árbol escoge un conjunto aleatorio de features para realizar cada split. Este número lo podemos configurar en sklearn.
3. Aplicamos boostrapping, es decir, cada árbol entrena con una muestra aleatoria con reemplazamiento del conjunto de train.
4. Una vez entrenados los árboles, aplicamos el sistema de votación de bagging para las predicciones.

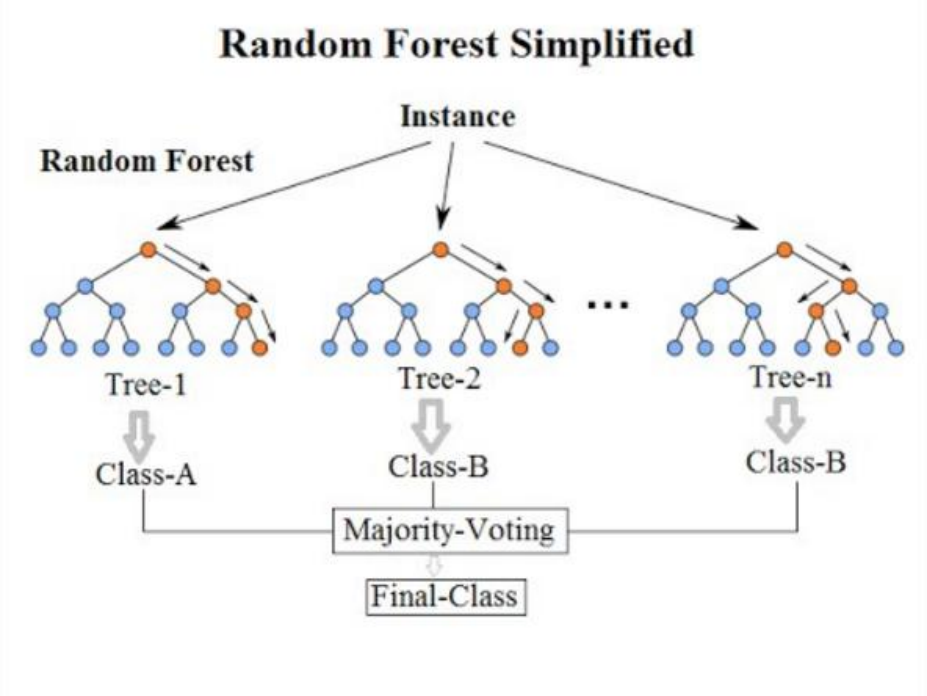

Feature importance

Una característica interesante que tiene Random Forest es el feature importance. Nos da una medida de cuánto aporta cada feature a las predicciones. Se calcula para cada feature la aportación que ha hecho al gini o entropía. Para todos los árboles. Calculamos la media de la aportación de cada feature.

Por suerte sklearn ya realiza esta operación por nosotros, y lo normaliza a 1, de tal manera que las features más importantes estarán cercanas a 1.

```
>>> from sklearn.datasets import load_iris
>>> iris = load_iris()
>>> rnd_clf = RandomForestClassifier(n_estimators=500, n_jobs=-1)
>>> rnd_clf.fit(iris["data"], iris["target"])
>>> for name, score in zip(iris["feature_names"], rnd_clf.feature_importances_):
...     print(name, score)
...
sepal length (cm) 0.112492250999
sepal width (cm) 0.0231192882825
petal length (cm) 0.441030464364
petal width (cm) 0.423357996355
```

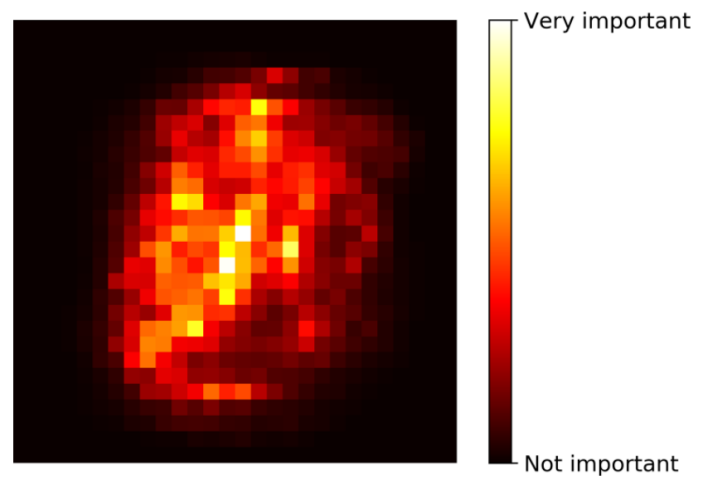

Feature importance para predicción de números

Boosting

Boosting

En el caso del bagging, teníamos un conjunto de modelos independientes, cuyos outputs agregados servían para el output final. En boosting los modelos se entrenan secuencialmente y por tanto existe una dependencia entre ellos.

Básicamente en esta técnica los modelos van intentando mejorar su predecesor, recibiendo los errores del mismo, e intentando mejorar su resultado

Los algoritmos más utilizados son:

1. AdaBoost
2. Gradient Boosting
3. XGBoost

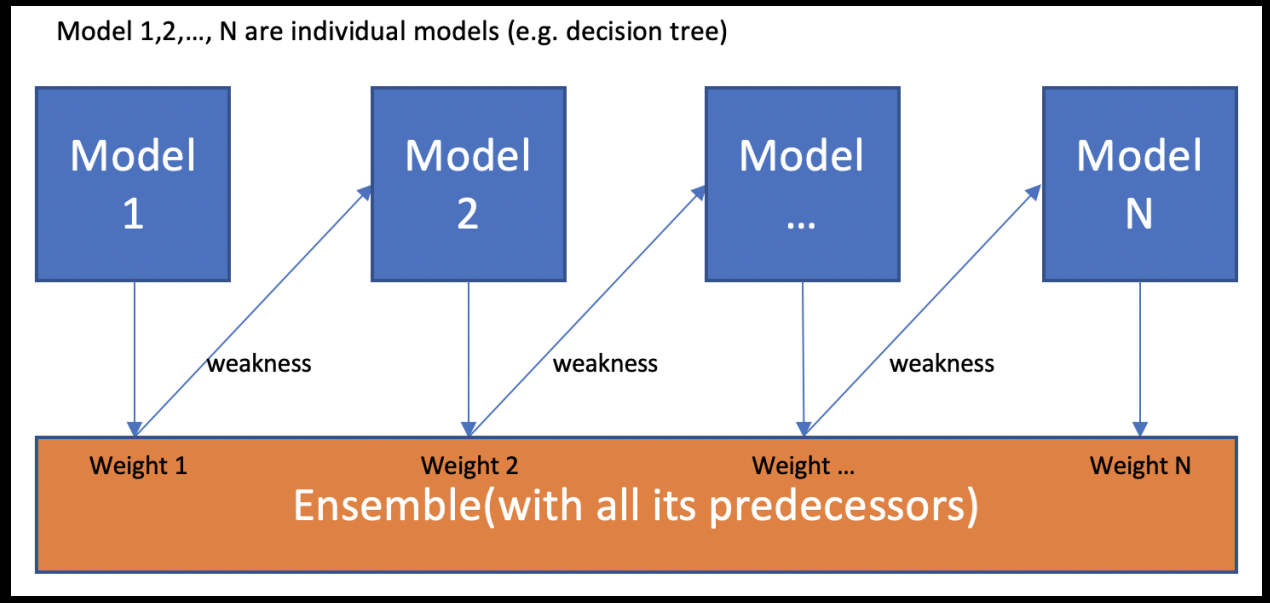

AdaBoost (Adaptive Boosting)

Cómo funciona AdaBoost:

1. **Modelo base (weak learner):**
   AdaBoost se basa en entrenar una secuencia de modelos simples o débiles (generalmente árboles de decisión poco profundos, también conocidos como *stumps*). El objetivo es corregir iterativamente los errores cometidos por los modelos anteriores.

2. **Pesos de las observaciones:**
   Cada observación del conjunto de entrenamiento tiene un peso asociado. Inicialmente, todas las observaciones tienen el mismo peso. Después de entrenar un modelo, las observaciones mal clasificadas reciben un peso mayor, de modo que el siguiente modelo se enfoque más en corregir esos errores.

3. **Combinación de modelos:**
   Cada modelo débil se combina con los modelos anteriores mediante un peso que refleja su precisión. La predicción final se realiza a través de un voto ponderado de todos los modelos.

AdaBoost (Adaptive Boosting)

Se trata de un conjunto de modelos iguales (árboles de decisión normalmente) que actúan de manera secuencial. Las predicciones (junto con sus errores) del modelo predecesor sirven de input para el siguiente, de tal manera que se intenta corregir el error del modelo. Se pone foco en los peores errores.

Según lo bien que lo haga cada modelo intentando corregir los errores, se le aplicará un parámetro α diferente.
Una vez entrenados, el output del modelo final será una combinación lineal de todos los estimadores, teniendo en cuenta el peso de cada uno, α.

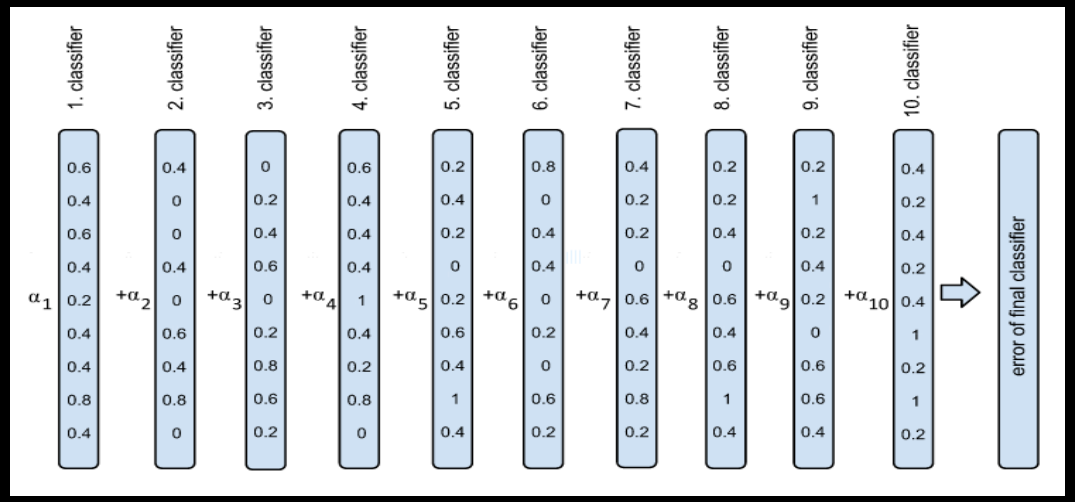

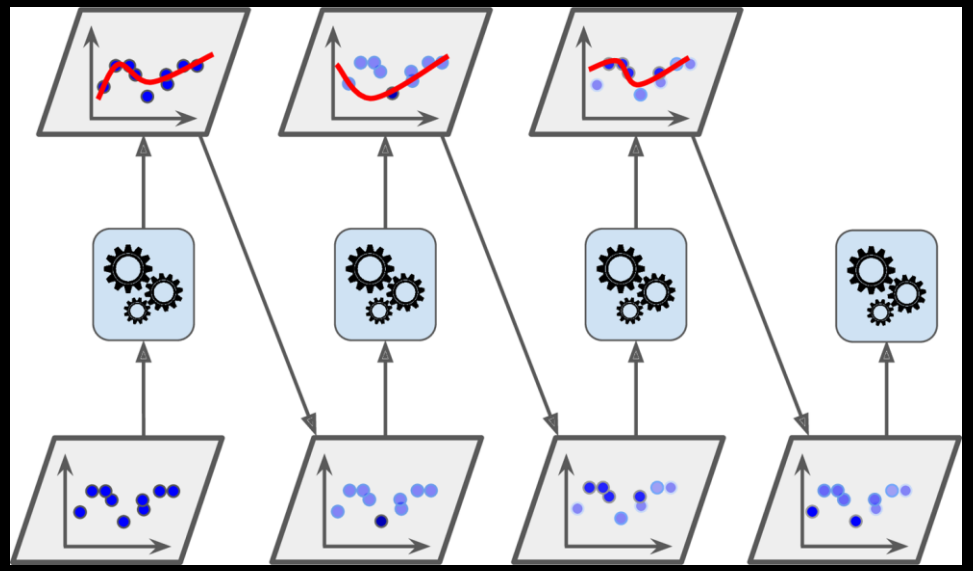

GradientBoost

Cómo funciona Gradient Boosting:

1. **Modelo base:**
   Como en AdaBoost, utiliza un modelo débil (generalmente árboles de decisión poco profundos). Sin embargo, Gradient Boosting se centra en minimizar una función de pérdida utilizando el gradiente descendente.

2. **Minimización de la pérdida:**
   En cada iteración, Gradient Boosting ajusta un nuevo modelo para corregir los errores residuales del modelo anterior, de forma que minimice la pérdida de manera más eficiente.

3. **Combina predicciones:**
   Los modelos se suman de forma secuencial, y el modelo final es la suma ponderada de todos los modelos ajustados.

GradientBoost

Al igual que el AdaBoost, el GradientBoost trabaja sobre un conjunto secuencial de modelos (árboles de decisión), tratando de corregir a su predecesor. Sin embargo, cuando el AdaBoost iba actualizando los pesos de cada observación, el GradientBoosting intenta ajustar, minimizar los errores (residuos) del modelo predecesor.

El modelo final será una combinación lineal de todos los estimadores.

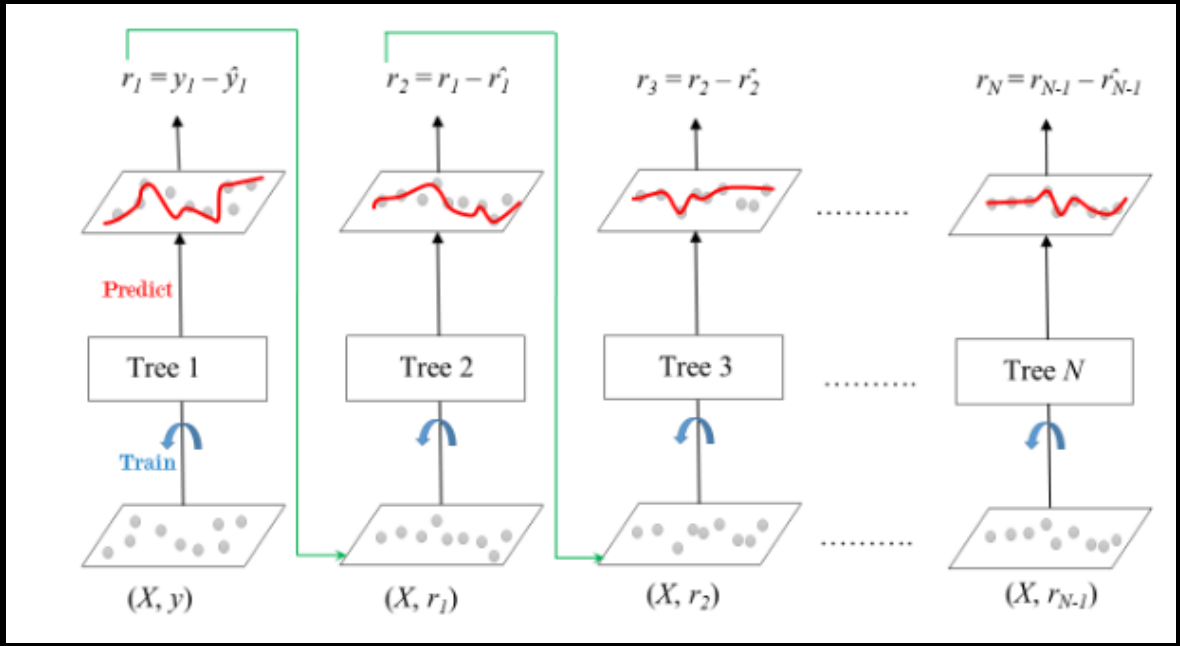

XGBoost

XGBoost es una biblioteca con una versión mejorada del algoritmo GradientBoosting.

Se destaca por su alta eficiencia, flexibilidad y precisión en diversas tareas de regresión y clasificación. Fue diseniada para manejar datos tabulares y puede trabajar con datasets grandes o complejos.

Bibliografía

Hands on Machine Learning
https://learning.oreilly.com/library/view/hands-on-machine-learning/9781492032632/ch07.html#ensembles_chapter

https://towardsdatascience.com/simple-guide-for-ensemble-learning-methods-d87cc68705a2

https://towardsdatascience.com/how-does-xgboost-work-748bc75c58aa