Machine Learning
KNN

Importante que las features estén escaladas porque si no el cálculo de las distancias es muy diferente con valores altos o bajos

No se usa tanto para predecir como para rellenar nulos. Los completa con datos de los puntos más cercanos (preguntar, no sé si lo he entendido)

¿Qué es el KNN?

- *KNN por sus siglas del inglés k-nearest neighbor.*
- El método KNN es un método de **clasificación** supervisado que estima la probabilidad a posteriori de que un elemento x pertenezca a la clase Cj a partir de la información proporcionada por el conjunto seleccionado.
- La clasificación se calcula a partir de un voto de mayoría simple de los vecinos más cercanos de cada punto: a un punto de consulta se le asigna la clase de datos que tiene más representantes dentro de los vecinos más cercanos del punto.

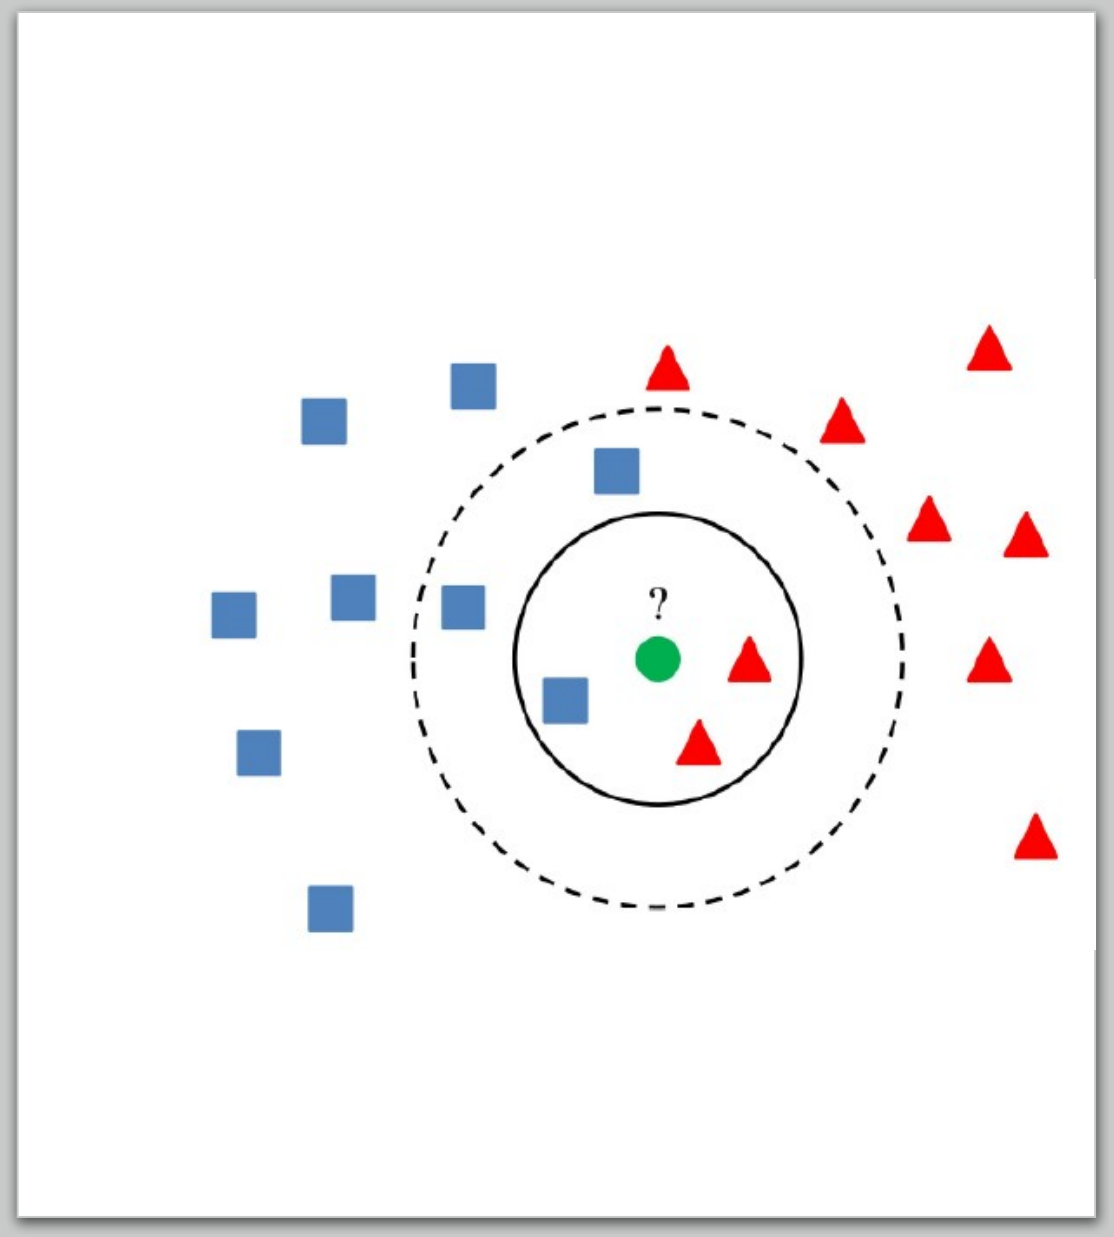

¿Cómo funciona?

- ¿Qué criterio utilizamos? Normalmente la distancia Euclídea.
- Sklearn, utiliza el aprendizaje basado en los K vecinos más cercanos de cada punto de consulta, donde K es un valor entero especificado por el usuario.
- Se suelen utilizar números impares para evitar empates.
- Lazy Learn Algorithm: no entrena y simplemente guarda el dataset. La computación se produce en predicción.
- Funciona bien con datasets pequeños
- No requiere de suposiciones en los datos
- Recomendable escalar

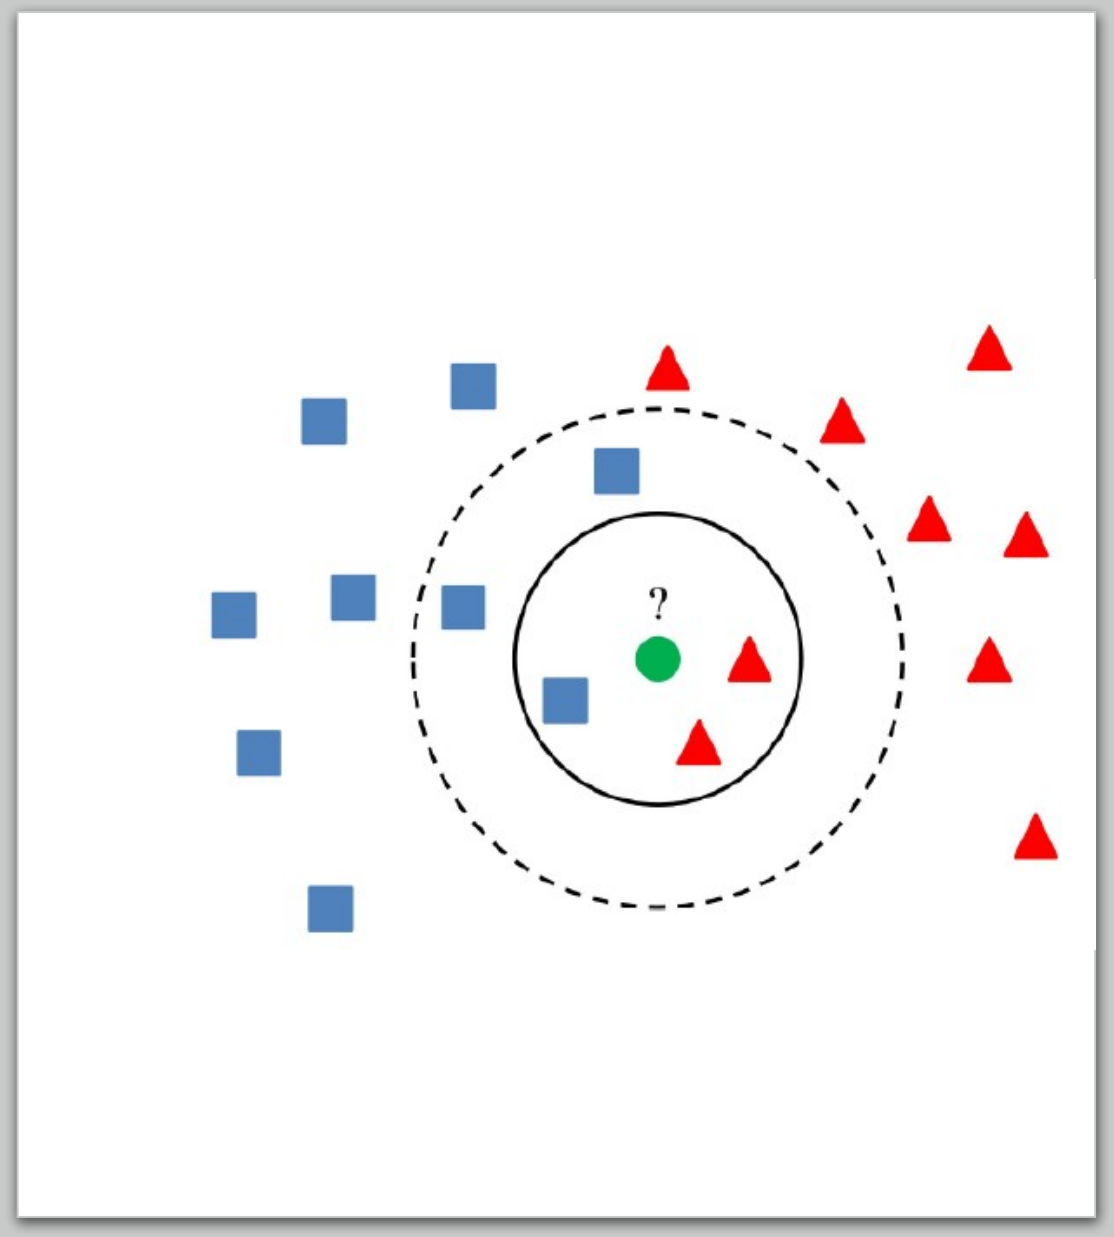

Distancia Euclídea

Euclidean Distance between (x_1, y_1) and(x_2, y_2) = $\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$

- El enfoque euclidiano, es la medida de distancia más utilizada para calcular la distancia entre las muestras de prueba y los valores de datos entrenados.

- Podemos calcular la distancia euclídea en un espacio n-dimensional.

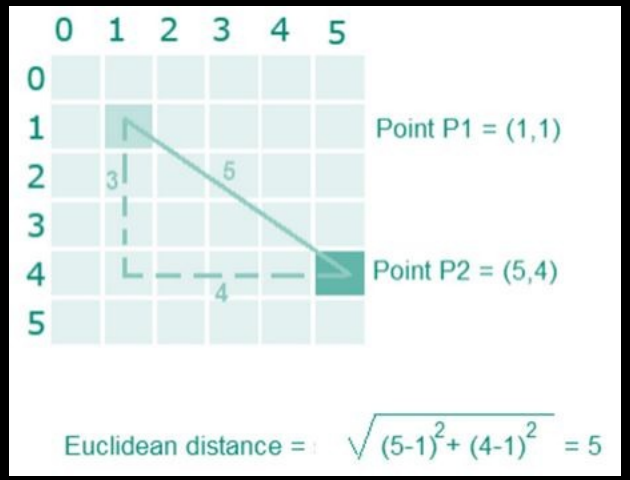

En general, la distancia euclidiana entre los puntos $P = (p_1, p_2, \ldots, p_n)$ y $Q = (q_1, q_2, \ldots, q_n)$, del espacio euclídeo *n*-dimensional, se define como:

$$d_E(P, Q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_n - q_n)^2} = \sqrt{\sum_{i=1}^{n} (p_i - q_i)^2}.$$

¿Cómo seleccionamos el valor óptimo de K?

- La mejor elección de k depende fundamentalmente de los datos.
- No existen métodos estadísticos predefinidos para encontrar el valor más favorable de K.
- Iniciamos un valor K aleatorio y calculamos.
- Investigación “iterativa”.
- Elegir valores pequeños de K conduce a límites de decisión muy sensibles o inestables.
- Para clasificar, elegir valores mayores de K nos suaviza esos límites de decisión (reducimos efecto ruido).

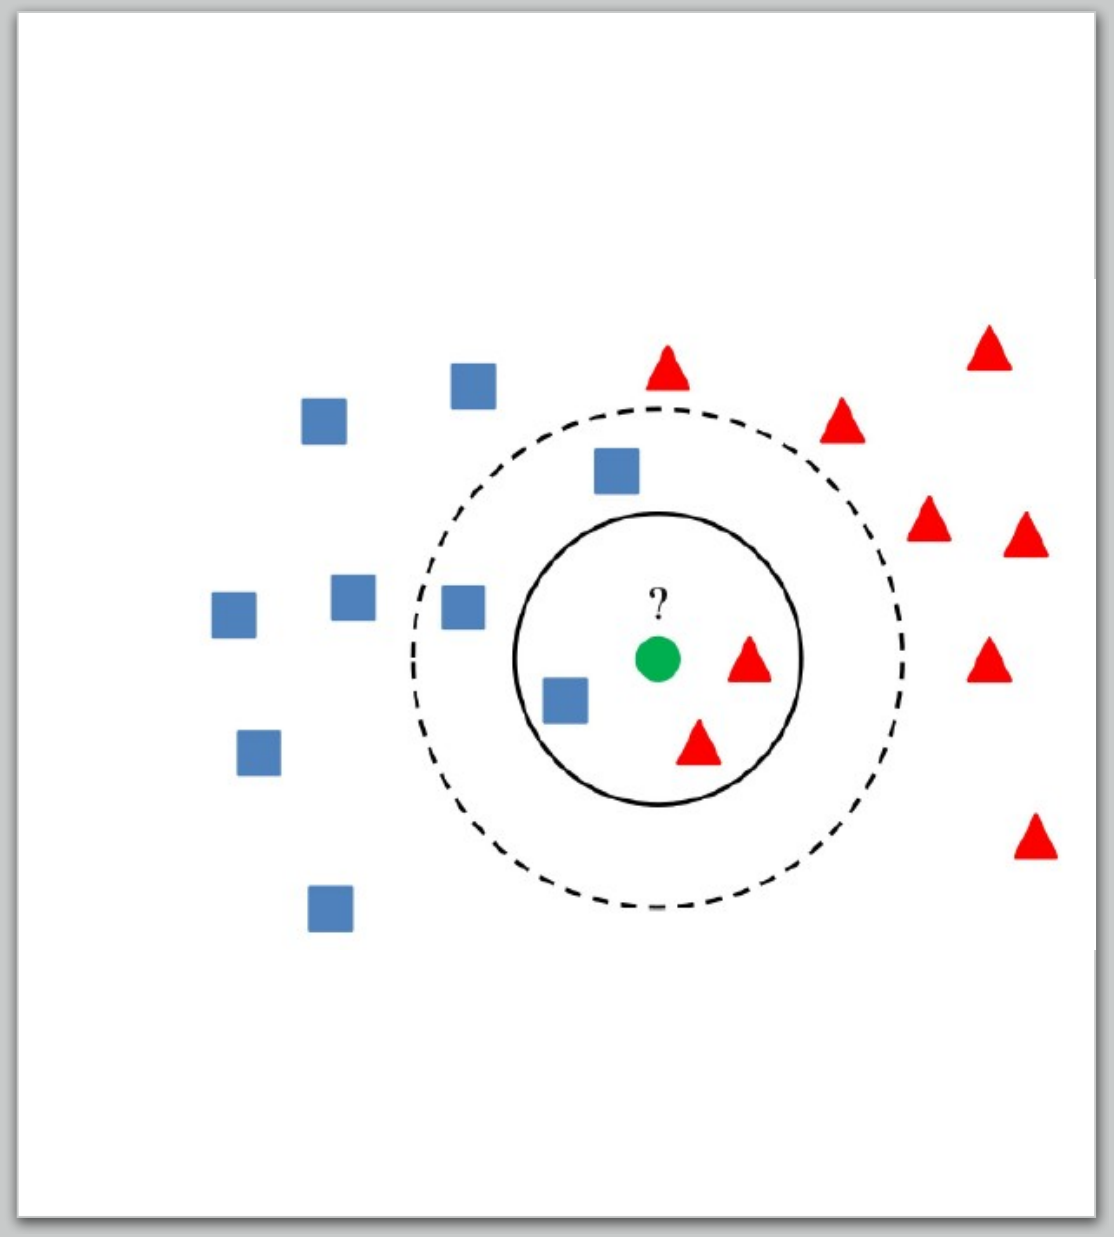

Escalar variables

- Los algoritmos basados en la distancia se ven afectados por la escala de las variables.
- Por ello, debemos tener las variables en rangos similares.
- No tiene sentido calcular distancias para variables con escalas muy diversas: variable edad vs variable ingresos.
- Para ello utilizaremos los distintos tipos de escalado:
  - Estandarización
  - Min-Max scaler
  - etc

~~*Distancia euclídia = [(100000–80000) ^ 2 + (30–25) ^ 2] ^ (1/2)*~~

¿Cómo evaluamos el modelo?

- Cambiar el valor de K puede afectar el rendimiento del modelo, por lo que debemos buscar su valor óptimo.

- Para escoger el valor óptimo de K utilizaremos las métricas de medida de performance:
    - Precisión
    - F1-score
    - Matriz de confusión
    - AUC
    - etc

- Problemas de rendimiento para datasets muy grandes.

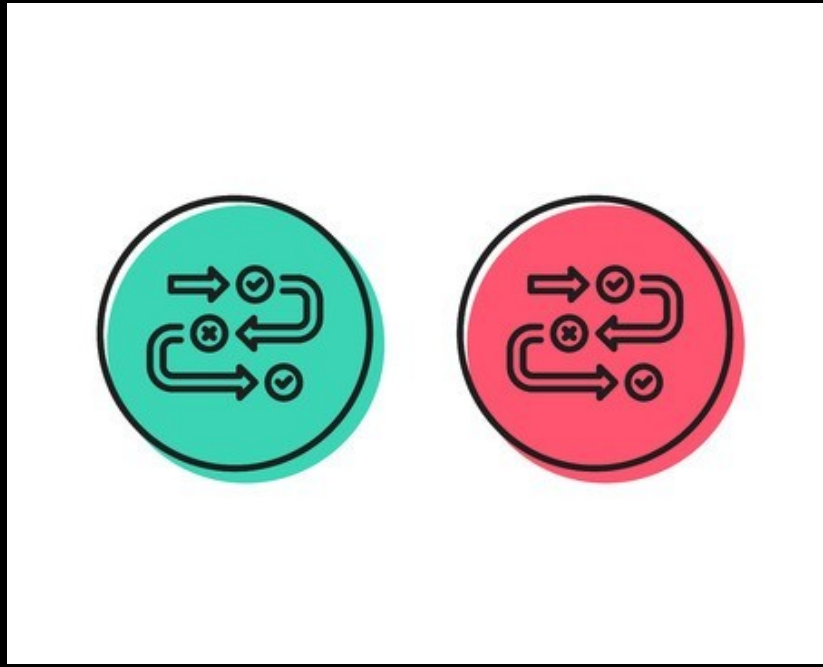

Overfitting en KNN

‘K’s muy bajos producen overfitting

‘K’s altos son más consistentes en los rangos de separación

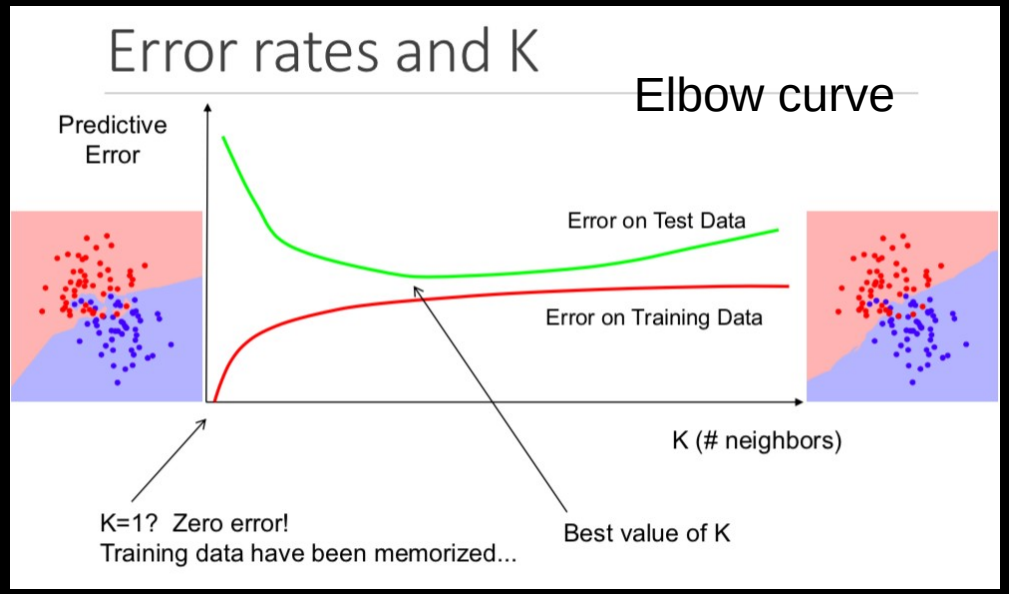

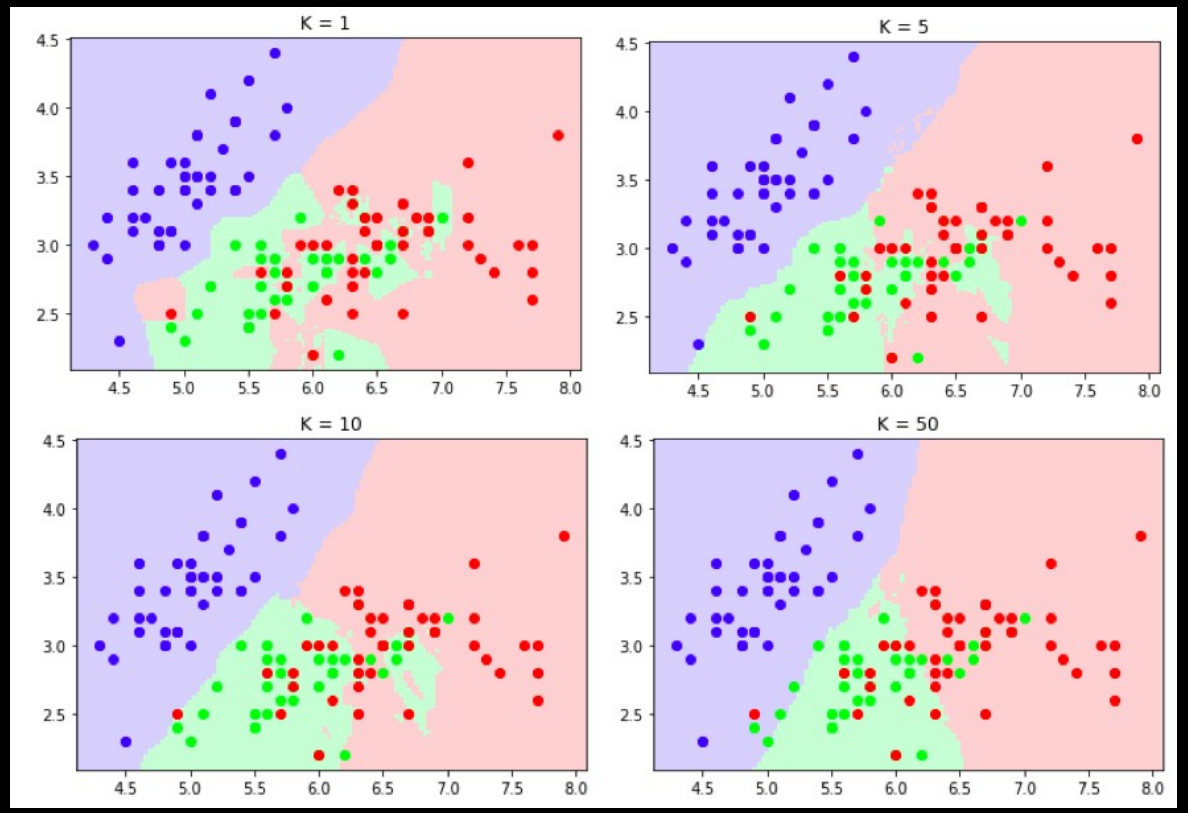

KNN Regressor

- Se calculan las distancias de cada punto al target
- Se eligen K-vecinos
- El output será la media de los targets de los K-vecinos

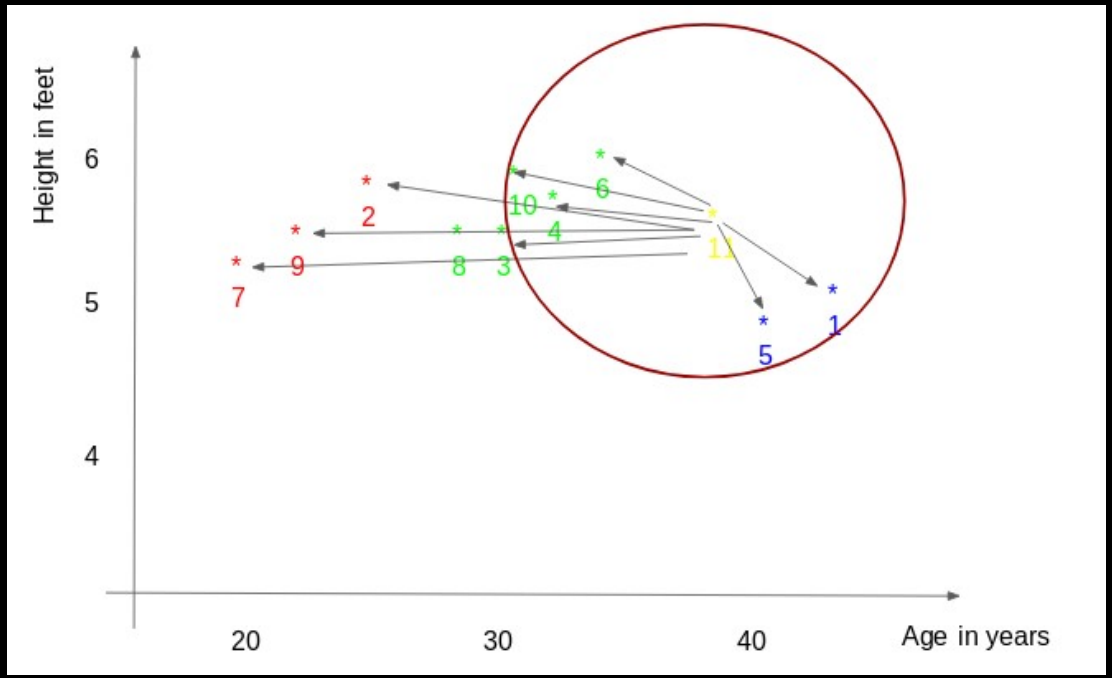

ID	Height	Age	Weight
1	5	45	77
4	5.9	34	59
5	4.8	40	72
6	5.8	36	60
10	5.6	32	58

(77+59+72+60+58)/5

Preguntas