Machine Learning – Grid Search & Pipelines

¿Cuál va a ser el mejor modelo para mi problema de ML?

Escogemos un modelo, por ejemplo Decision Tree. Voy a probar varias combinaciones de hiperparámetros para ver cuál me da mejor rendimiento

Criterion: ‘gini’ o ‘entropy’
max_depth: profundidad del árbol
min_samples_split

Pruebo con gini, max_depth=2, min_samples_split=2

Pruebo con gini, max_depth=3, min_samples_split=2

Pruebo con gini, max_depth=4, min_samples_split=2

Pruebo con gini, max_depth=5, min_samples_split=2

Pruebo con gini, max_depth=6, min_samples_split=2

Pruebo con gini, max_depth=7, min_samples_split=2

Pruebo con gini, max_depth=2, min_samples_split=3

Pruebo con gini, max_depth=2, min_samples_split=4

Pruebo con gini, max_depth=2, min_samples_split=5

Pruebo con gini, max_depth=2, min_samples_split=6

Pruebo con gini, max_depth=2, min_samples_split=7

Pruebo con gini, max_depth=2, min_samples_split=8

Pruebo con entropy, max_depth=2, min_samples_split=2

Pruebo con entropy, max_depth=3, min_samples_split=2

Pruebo con entropy, max_depth=4, min_samples_split=2

Pruebo con entropy, max_depth=5, min_samples_split=2

Pruebo con entropy, max_depth=6, m

Pruebo con entropy, max_depth=7, m

Pruebo con entropy, max_depth=4, m

Pruebo con entropy, max_depth=5, m

Pruebo con entropy, max_depth=6, m

Pruebo con entropy, max_depth=7, m

Pruebo con entropy, max_depth=2, min_samples_split=3

Pruebo con entropy, max_depth=2, min_samples_split=4

Pruebo con entropy, max_depth=2, min_samples_split=5

Pruebo con entropy, max_depth=2, min_samples_split=6

depth=2, min_samples_split=7

depth=2, min_samples_split=8

depth=2, min_samples_split=5

depth=2, min_samples_split=6

depth=2, min_samples_split=7

depth=2, min_samples_split=8

Calculo errores de todos los modelos, y elijo los hiperparámetros cuyo modelo tenga el mínimo error.
Por ejemplo, entropy, max_depth=3, min_samples_split=4

Grid Search

Grid Search

Proceso a la hora de probar hiperparámetros:
1 - pruebo un rango amplio -no hace falta que sea un range, pongo unos valores intermedios y luego punto 2-
2- con lo que me de de best acoto un poco (centro en ese rango o si me ha dado un extremo desplazo un poco

No es necesario iterar manualmente cada una de esas combinaciones, tenemos herramientas en sklearn para hacerlo de manera automática.

Existen varias técnicas como Grid Search, Random Search, Optimización Bayesiana…

La técnica más utilizada es Grid Search

le paso un diccionario en el que la clave es el nombre del hiperparámetro y el contenido una lista con los valores a probar de ese parámetro

1. Escojo un modelo
2. Elijo hiperparametros de ese modelo que quiero probar
3. Escojo un rango de valores para cada hiperparametro
4. Entrenamos mediante la función GridSearchCV (veremos en demo), que nos dará la mejor combinación de hiperparametros.
5. CV viene incluido en el argumento “cv”

hace internamente crossvalidation que controla el overfit
(aunque siempre sobre los datos de train

```
grid = {
        "max_depth": [3, 5, 10,15, 20],
        "max_features": [3, 4, 6, 8],
        "min_samples_split": range(2, 10)
        }
```

Pipelines

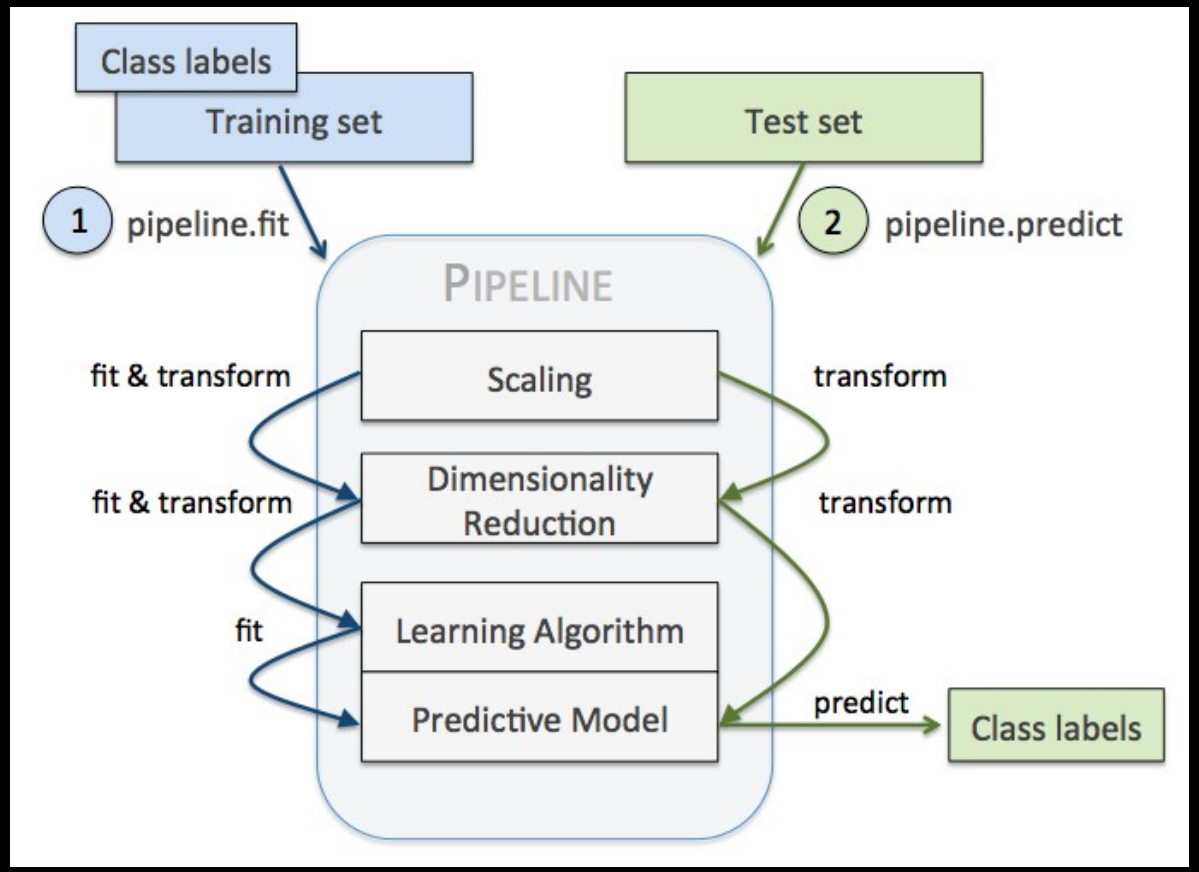
Class labels
Training set
Test set
1
pipeline.fit
2
pipeline.predict
PIPELINE
fit & transform
Scaling
transform
fit & transform
Dimensionality Reduction
transform
fit
Learning Algorithm
Predictive Model
predict
Class labels

Bibliografía

https://learning.oreilly.com/library/view/hands-on-machine-learning/9781492032632/ch02.html#idm45022189270600

https://towardsdatascience.com/gridsearch-the-ultimate-machine-learning-tool-6cd5fb93d07